

《计算机科学导论》课程

数据挖掘

上海交通大学计算机科学导论课程组



致谢：本课件由周昕逸@CS2021M.SJTU编写，洪义整合，高晓沅终校定稿。

什么是数据挖掘？

- 对数据进行**收集、清洗、加工**和**分析**并从中**获取有用知识**的过程。

为什么需要数据挖掘？

- 进入大数据时代，各类自动化系统生成的数据已达到PB或EB的数量级，如：万维网、财务交往、用户交互、传感器技术和物联网。



- 数据挖掘旨在使用一系列处理流程，从不同格式的异构数据源中为特定应用目标提取**简明扼要的、可操作性强的**洞察及理解。

数据挖掘简介：数据挖掘的概念

数据挖掘的经典案例

沃尔玛：
啤酒与尿布



奥巴马：
美国总统大选连任




微软：
预测奥斯卡



招聘网站：
职位信息

安全数据挖掘工程师	面议
北京 3-5年 学历不限	
字节跳动	
直播/短视频/新闻传媒 C轮	195天前
数据挖掘专家-淘系技术部	40-45k*12
北京 3-5年 本科	
阿里巴巴集团	
互联网综合 上市	179天前
数据挖掘工程师 - 【电商风控】	30-60k*12
北京 3-5年 本科	
快手	
直播/短视频 D轮及以上	211天前
数据挖掘工程师	面议
北京 1年以内 硕士	
字节跳动	
直播/短视频/新闻传媒 C轮	163天前
抖音大数据工程师-数据挖掘方向	面议
北京 1-3年 学历不限	
字节跳动	
直播/短视频/新闻传媒 C轮	120天前

数据挖掘简介：数据挖掘的过程



图片来源：
《数据挖掘：原理与实践》

数据收集：硬件、软件、人工

数据预处理

- **特征提取：**将大量的原始文件、系统日志、商业交易转换为有意义的数据库特征
- **清洗与集成**
 - ◆ **数据清洗：**处理错误或缺失的条目，维护一致性
 - ◆ **特征选择：**将高维特征空间转换为更适合分析的新数据空间
 - ◆ **数据转换：**将一些属性转换为另一种相同或类似数据类型的属性

分析过程与算法：通过数据挖掘过程的“超级问题”或基本模块解决个性化应用

目 录



01 数据准备阶段

02 关联模式挖掘


03 聚类

04 分类

01. 数据准备阶段：数据收集

数据收集的途径

- 传感器网络等专门的硬件
- 手工录入的用户调查
- Web爬虫等软件工具
- 从其他系统批量导入



01. 数据准备阶段：基本数据类型-非依赖型数据

非依赖型数据(Nondependency-Oriented Data):

- 如多维数据或文本数据，数据项或属性之间没有任何依赖关系。
- 多维数据通常包含一组记录（又称数据点、实例、样例、交易记录、实体、元组、对象或特征向量）
- 每条记录都包含一组字段（又称属性、维度或特征）
- 例：人口统计数据集

Table 1.1: An example of a multidimensional data set

Name	Age	Gender	Race	ZIP code
John S.	45	M	African American	05139
Manyona L.	31	F	Native American	10598
Sayani A.	11	F	East Indian	10547
Jack M.	56	M	Caucasian	10562
Wei L.	63	M	Asian	90210

记录(Record)

字段(Field)

01. 数据准备阶段：基本数据类型-非依赖型数据

非依赖型数据的分类

Table 1.1: An example of a multidimensional data set.

Name	Age	Gender	Race	ZIP code
John S.	45	M	African American	05139
Manyona L.	31	F	Native American	10598

- **定量型的多维数据(Quantitative Multidimensional Data)**
 - ◆ 连续的、数值的或定量的属性：如年龄
 - ◆ 便于分析处理：均值、方差等运算
- **类别型和混合型数据(Categorical and Mixed Attribute Data)**
 - ◆ 类别型数据：离散且无次序的值，如性别、种族和邮政编码
 - ◆ 混合型数据：数据项既有定量型的又有类别型的

01. 数据准备阶段：基本数据类型-非依赖型数据

非依赖型数据的分类

- 二元和集合数据(Binary and Set Data)

- ◆ 多维类别型数据的特例：表示离散的类别
- ◆ 多维定量型数据的特例：可以给予两个值先后次序
- ◆ 集合归属数据：表示元素是否隶属于某个集合

$$I(x) = \begin{cases} 1, & \text{if } x \in \mathcal{X} \\ 0, & \text{otherwise} \end{cases}$$

- 文本数据(Text Data)


- ◆ 直接表示为字符串时，单词之间有次序关系，是一种依赖型数据
- ◆ 表示为文档术语矩阵时，是一种多维定量型数据，存在数据稀疏性问题

	酒	三国	
将进酒	4	0	...
念奴娇·赤壁怀古	0	1	...
	...	...	...

01. 数据准备阶段：基本数据类型-依赖型数据

依赖型数据(Dependency-Oriented Data):

- 数据项之间可能有某种隐式的相互依赖关系（时间、空间）或者显示的依赖关系（比如数据项之间有某种网络的链接关系）。
- 隐式依赖关系：相关领域有“通常”存在的、数据项之间的依赖关系，如传感器连续收集的时序数据
- 显式依赖关系：用图或网络数据显式地给出数据项之间的关系




01. 数据准备阶段：基本数据类型-依赖型数据

时间序列数据： 随着时间的推移通过连续测量所生成的数值

- 多元时间序列的定义：一个长度为 n ，维度为 d 的矩阵在 $t_1, \dots, t_n$ 这 n 个时间戳的每个时间点上都有 d 个定量型特征
 - ◆ 上下文属性：对应于时间维度，如传感器数据中表示测量时间的时间戳
 - ◆ 行为属性：对应于测量的数值，如传感器数据的读数
- 典型问题：时序预测
 - ◆ 根据单变量 i 的历史时间序列 $z_{i,t}$ ，预测未来时序的行为

$$z_{i,0}, \dots, z_{i,T-1}, z_{i,T} \Rightarrow P(z_{i,T+1}, z_{i,T+2}, \dots, z_{i,T+h})$$



01. 数据准备阶段：基本数据类型-依赖型数据

离散序列和字符串

- 多元离散序列的定义：一个长度为 n ，维度为 d 的矩阵在 $t_1, \dots, t_n$ 这 n 个时间戳的每个时间点上都有 d 个离散值

- ◆ 事件日志：计算机系统依据用户的活动创建日志

例如，一个金融网站上的用户操作日志如下，可能代表用户试图闯入一个有密码保护的系统

Login Password Login Password Login Password

- ◆ 生物数据：如核苷酸、氨基酸字符串，提供了有关蛋白功能的特性信息


01. 数据准备阶段：基本数据类型-依赖型数据

空间数据：上下文属性用于表示空间位置

- 如气象学数据中的经度、纬度为上下文属性

时空数据：包含时间和空间两种属性


- 测量时间和空间的动态行为属性：如随着时间的推移测量海面温度变化
- 轨迹数据：在时空环境下，对一个或多个移动对象运动过程的采样所获得的数据信息



01. 数据准备阶段：基本数据类型-依赖型数据

时空数据举例


- 出租车订单数据（订单的起终点经纬度、订单类型、出行品类、乘车人数等）
- 百度迁徙数据（迁入和迁出人口地和规模）
- 微信宜出行数据（人流量、经纬度等）
- 地铁刷卡数据（进出站流量、乘车时间等）



01. 数据准备阶段：基本数据类型-依赖型数据

网络和图数据：

- 一个网络 $G = (N, A)$ 包含一组节点 N 和一组边 A ，数据值对应于网络中的节点，而数据值之间的关系对应于网络中的边。边 (i, j) 可以是有向或无向的，取决于当前的应用。
- Web图：节点对应于网页，有向边表示超链接及方向，网页中的文本是相应网页节点的属性。
- 社交网络：节点对应于社交网络用户，边对应于朋友关系，社交页面的内容是节点上的属性数据，邮件及聊天的通信记录是边上的属性数据。
- 化合物数据库：节点对应于元素，边对应于元素之间的化学键。




01. 数据准备阶段：数据预处理概述

为什么要对数据预处理？

- 低质量的数据导致低质量的挖掘结果
- 影响数据质量的因素有：准确性、完整性、一致性、时效性、可信性、可解释性

数据预处理的主要步骤

- 数据清洗
- 数据集成
- 数据归约
- 数据变换



图片来源：《数据挖掘：概念与技术》

01. 数据准备阶段：数据清洗

缺失值

- 填充方法
 - ◆ 直接删除法：如分类问题中缺少类标号时
 - ◆ 人工填写缺失值
 - ◆ 使用一个全局常量填充：如 NAN 或 $-\infty$ 等
 - ◆ 使用属性的均值、众数、中位数填充
 - ◆ 使用最可能的值：如通过回归、贝叶斯推理、决策树等来推断
- 填充工具
 - ◆ Python: Pandas中的`fillna()`函数、`interpolate()`插值函数, sklearn库函数等
 - ◆ R: Hmisc包、missMDA包等, 包含多种函数, 支持简单插补、多重插补和典型变量插补

01. 数据准备阶段：数据清洗

噪声（错误或不一致）：被测量的变量的随机误差或方差

- 光滑法

- ◆ 分箱(Binning)：通过考察数据的近邻来光滑有序数据值

- 例：一组数据4,8,15,21,21,24,25,28,34，划分到3个箱中

- ◆ 回归(Regression)：用一个函数拟合来光滑数据

- 领域知识约束法：限制了属性值的范围和不同属性之间的约束

- ◆ 如：生日与身份证号之间的关系，国家-城市-区之间的限制

- 检测法：利用数据的统计行为特征检测异常点

划分为（等频的）箱：

箱1: 4, 8, 15

箱2: 21, 21, 24

箱3: 25, 28, 34

用箱均值光滑：

箱1: 9, 9, 9

箱2: 22, 22, 22

箱3: 29, 29, 29

用箱边界光滑：

箱1: 4, 4, 15

箱2: 21, 21, 24

箱3: 25, 25, 34

01. 数据准备阶段：数据归约

数据归约的作用：更简洁地表示数据，但仍接近于保持数据的完整性

数据归约的策略

- 维归约：减少考虑的随机变量或属性的个数
 - ◆ 小波变换、主成分分析等
 - ◆ 特征选择工具：sklearn.feature_extraction模块、FeatureSelector库等
- 数量归约：用较小的数据表示形式替换原数据
 - ◆ 参数方法：使用模型估计数据，仅存储模型参数
 - ◆ 非参数方法：直方图、聚类、抽样、数据立方等
- 数据压缩：使用变换压缩数据，如果原数据能从压缩后的数据重构，称为“无损的”

01. 数据准备阶段：数据变换

数据规范化：把属性数据按比例缩放使之落入一个特定的小区间，如 $[-1,1]$ 或 $[0,1]$

为什么要规范化？ 属性值的度量单位可能影响数据分析，具有较大值域的属性倾向于有较大的影响或较高的权重。

规范化的方法

- min-max规范化：设 $\min_A$, $\max_A$ 分别为属性A的最小值和最大值，min-max规范化

$$v'_i = \frac{v_i - \min_A}{\max_A - \min_A} (\text{new_max}_A - \text{new_min}_A) + \text{new_min}_A$$

- z-score规范化（标准化）


$$v'_i = \frac{v_i - \bar{A}}{s_A}$$

- ◆ 使用均值和标准差进行规范化

- ◆ 其中 $\bar{A}$ 表示均值， s_A 表示标准差

01. 数据准备阶段：数据挖掘使用的技术

作为一个应用驱动领域，数据挖掘吸纳了许多领域的大量技术



01. 数据准备阶段：数据挖掘的主要任务

考虑一个具有 n 个记录和 d 个属性的多维数据库 D ，每行对应于一条记录，每列对应于一个维度。数据条目之间的关系有两种：

- 列之间的关系

- ◆ **关联模式挖掘**：确定在一行中各值之间频繁或罕见的关系
- ◆ **数据分类**：通过其他列与特殊列的关系预测特殊列的缺失值

- 行之间的关系

- ◆ **聚类**：把行分成多个子集，使得属于一个子集中的行在相应列的值上具有相关性
- ◆ **异常检测**：一行的列值与其他行中相应的列值很不一样（**需要用到大量概率统计知识**）

d columns/attributes

n rows/records

Data Matrix

$$\begin{bmatrix} 1 & 0 & \cdots & 2 \\ 0 & 3 & \cdots & 5 \\ 3 & 0 & \cdots & 8 \\ 7 & 0 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 2 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{n \times d}$$

这四个问题构成了数据挖掘的主要任务。


01. 数据准备阶段：异常检测简介

什么是异常点？


- 与其他观察值偏离很多的值，也称作孤立点、不和谐点、离群点或不规则点

异常点的类型

- 全局异常点：显著地偏离数据集中的其他对象
- 情境（条件）异常点：关于对象的特殊情境，显著地偏离数据集中的其他对象
 - ◆ 如：今天的温度是28°C，这是一个异常点吗？依赖于时间和地点。
- 集体异常点：数据对象的一个子集显著地偏离数据集中的其他对象



全局异常点



集体异常点



01. 数据准备阶段：异常检测简介

异常检测模型的输出：数据点的异常程度被量化为一个数值，称为异常分(outlier score)

- 实数值的异常分
 - ◆ 定量地表达一个数据点是异常点的倾向
 - ◆ 越大（越小）的分数说明数据点越可能是异常点
 - ◆ 可以为概率值，量化是异常点的可能性
- 二元标签：输出一个点是否为异常点的二元结果

异常检测的应用

- 数据清洗：去除噪声
- 信用卡欺诈：检测罕见的信用卡活动模式
- 网络入侵检测：检测网络流量中罕见的记录或罕见的趋势改变



目录



01

数据准备阶段

02

关联模式挖掘

03

聚类

04

分类

02. 关联模式挖掘：啤酒与尿布

Walmart
沃尔玛



!

和尿布一起购买最多的商品竟然是啤酒



?

男性顾客在购买婴儿尿片时，常会顺便买几瓶啤酒来犒劳自己



\$

将啤酒和尿布放置一起，两者的销量都大幅增加

关联规则应用

02. 关联模式挖掘：基本概念

以如下超市数据为例

$$U = \{Bread, Butter, Cheese, Eggs, Milk, Yogurt\}$$

tid	Set of items	Binary representation
1	$\{Bread, Butter, Milk\}$	110010
2	$\{Eggs, Milk, Yogurt\}$	000111
3	$\{Bread, Cheese, Eggs, Milk\}$	101110
4	$\{Eggs, Milk, Yogurt\}$	000111
5	$\{Cheese, Milk, Yogurt\}$	001011

support of $\{Bread, Milk\}$ is $\frac{2}{5} = 0.4$

support of $\{Cheese, Yogurt\}$ is $\frac{1}{5} = 0.2$

- 支持度(Support): 某个商品组合出现的次数与总次数之间的比例
- 频繁项集: 支持度大于等于最小支持度的集合
- 如果定义最小支持度 $minsup=0.3$, 则频繁项集为 $\{Bread, Milk\}$
- 支持度的一些性质:
 - ◆ 最小支持度越小, 频繁项集数越多
 - ◆ 支持度单调性: 项集的任意子集的支持度 $\geq$ 该项集的支持度
 - ◆ 向下闭包性: 频繁项集的每个子集也是频繁的

02. 关联模式挖掘：基本概念

以如下超市数据为例 $U = \{Bread, Butter, Cheese, Eggs, Milk, Yogurt\}$

- 最小支持度=0.3时

tid	Set of items	Binary representation
1	$\{Bread, Butter, Milk\}$	110010
2	$\{Eggs, Milk, Yogurt\}$	000111
3	$\{Bread, Cheese, Eggs, Milk\}$	101110
4	$\{Eggs, Milk, Yogurt\}$	000111
5	$\{Cheese, Milk, Yogurt\}$	001011

- **最大频繁项集**：在一个给定的最小支持度下，如果项集L是频繁的，且它的任何超集都不是频繁的，那么称L为最大频繁项集

$\{Bread, Milk\}, \{Cheese, Milk\}, \{Eggs, Milk, Yogurt\}$

- 通过最大频繁项集可以推导出所有的频繁项集
 - ◆ 为最大频繁项集的子集，共11个

02. 关联模式挖掘：基本概念

以如下超市数据为例 $U = \{Bread, Butter, Cheese, Eggs, Milk, Yogurt\}$

tid	Set of items	Binary representation
1	$\{Bread, Butter, Milk\}$	110010
2	$\{Eggs, Milk, Yogurt\}$	000111
3	$\{Bread, Cheese, Eggs, Milk\}$	101110
4	$\{Eggs, Milk, Yogurt\}$	000111
5	$\{Cheese, Milk, Yogurt\}$	001011

- **置信度(Confidence)**: 指当你购买了商品X, 会有多大的概率购买商品Y

$$conf(X \Rightarrow Y) = \frac{sup(X \cup Y)}{sup(X)}. \quad conf(\{Eggs, Milk\} \Rightarrow \{Yogurt\}) = \frac{sup(\{Eggs, Milk, Yogurt\})}{sup(\{Eggs, Milk\})} = \frac{0.4}{0.6} = \frac{2}{3}$$

- **关联规则**: 令X和Y为两个项集, 若满足以下两个条件, 则规则 $X \Rightarrow Y$ 是最小支持度为minsup和最小置信度为minconf的强关联规则.
 - ◆ 项集 $X \cup Y$ 的支持度 $\geq$ minsup, 即 $X \cup Y$ 是一个频繁项集
 - ◆ 规则 $X \Rightarrow Y$ 的置信度 $\geq$ minconf

02. 关联模式挖掘：关联规则生成框架

生成关联规则的总体框架


- 第一阶段：以最小支持度minsup，生成所有频繁项集，**计算密集**
- 第二阶段：以最小置信度minconf，从频繁项集中生成关联规则，**相对简单**
 - ◆ 给定一个频繁项集F，对于集合中的每个项集I，把I分解成所有可能的集合X和集合 $Y=I-X$ 的组合，满足 $I=X \cup Y$
 - ◆ 计算每条规则 $X \Rightarrow Y$ 的置信度，保留满足最小置信度要求的规则
 - ◆ **置信度单调性**：如果项集 X_1 、 X_2 和I满足 $X_1 \subset X_2 \subset I$ ，那么 $conf(X_2 \Rightarrow I - X_2) \geq conf(X_1 \Rightarrow I - X_1)$

例： $X_1=\{\text{bread}\}$ ， $X_2=\{\text{bread, butter}\}$ ， $I=\{\text{bread, butter, milk}\}$
 $conf(\{\text{bread, butter}\} \Rightarrow \{\text{milk}\}) \geq conf(\{\text{bread}\} \Rightarrow \{\text{butter, milk}\})$

02. 关联模式挖掘：频繁项集挖掘算法

暴力算法

- **主要思想**：生成所有的可能的频繁项集，在事务数据库上计算其支持率，检查给定的项集是否是每个事务的子集
- **穷举的问题**：一个项空间 U 除去空集共有 $2^{|U|} - 1$ 个不同的子集，当 $|U|$ 很大时，计算是不现实的
- **提高算法效率的方法**
 - ◆ 利用**向下闭包性**，通过剪除候选项集来缩小搜索空间
 - ◆ 对候选项集计数时，通过剪除已知的与此候选集不相关的事务，使计数更加高效
 - ◆ 使用紧凑的数据结构表示候选项集或事务数据库，实现快速的计数



02. 关联模式挖掘：频繁项集挖掘算法

枚举树算法

- 枚举树定义


- ◆ 每一个频繁项集对应树中的一个节点，根节点对应于null
- ◆ 一个节点的孩子节点只可以通过在当前节点的所有项之后增加一项来得到

- 算法流程

- ◆ 选择枚举树中的一个或多个节点
- ◆ 对于每个节点，确定候选扩展集合
- ◆ 统计生成的候选项集的支持率
- ◆ 把频繁候选项集添加到枚举树中

- 算法意义


- ◆ 几乎所有的频繁模式挖掘算法都可以看做是枚举树框架的变体或扩展
- ◆ 不同的生长策略（深度优先、广度优先）和不同的计数方法（数据结构）可以给出效率、空间需求、磁盘访问代价的不同折中方案



02. 关联模式挖掘：频繁项集挖掘算法

Apriori算法

- **主要思想**：由向下闭包性可知，频繁项集的任意子集也是频繁的，如果一个项集是非频繁的，那么对它的超集进行支持率计数就没有意义
- **算法流程**：
 - ◆ k=1开始，对比数据库计算k项集的支持度
 - ◆ 筛选掉小于最小支持度的项集
 - ◆ 当k项集不满足条件时，k+1项也不满足条件，即可剪枝，停止该方向的搜索
 - ◆ 否则k=k+1，重复1-3步



目录



01

数据准备阶段

02

关联模式挖掘

03

聚类

04


分类

03. 聚类：基本概念


聚类的定义：将数据集中的样本划分成若干个通常不相交的子集，使得类内相似度高，类间相似度低。

聚类的应用

- 数据汇总：从数据中提取摘要信息（或简明的见解）
- 客户分类：分析相似用户组的共同行为特性，如协同过滤
- 社交网络分析：通过连接关系而紧密聚集的节点通常属于相似的组



03. 聚类：早餐供应点设置方案




?

如何设置移动早餐供应点能够方便各个小区的居民?

情况1：有 1 个供应点

03. 聚类：早餐供应点设置方案



?


如何设置移动早餐供应点能够方便各个小区的居民?

情况1：有 1 个供应点

情况2：有 2 个供应点

聚类 (Clustering)

- 将数据集按相似度分成多个子集（通常不相交），每个子集称为一个类或簇（Cluster），使得类/簇内相似度高，类/簇间相似度低



03. 聚类：相似度度量

相似度：


- 描述数据样本间的接近程度
- 有 n 个特征的样本可转化为 n 维空间中的点

$$X = (x_1, x_2, \dots, x_n)$$

相似度度量

- 用特征间的距离函数计算
- 距离小，则相似度大；距离大，则相似度小
- 距离函数选择与样本特征类型及聚类目的有关

客户	年龄	薪资
小美	26	¥ 5,000
小庄	29	¥ 10,000
小贺	23	¥ 8,000



03. 聚类：两点间距离计算

两个包含 n 维特征的数据样本 $X = (x_1, x_2, \dots, x_n)$ 和 $Y = (y_1, y_2, \dots, y_n)$

欧氏距离


$$d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

曼哈顿距离

$$d = \sum_{i=1}^n |x_i - y_i|$$

- 又称 “街区距离”

即将之看作 n 维空间中的点计算距离



03. 聚类：两向量间距离计算

两个包含 n 维特征的数据样本 $X = (x_1, x_2, \dots, x_n)$ 和 $Y = (y_1, y_2, \dots, y_n)$


余弦相似度： 向量空间中的两个向量夹角 θ 的余弦值

$$\cos\text{Sim} = \cos(\theta) = \frac{X \cdot Y}{\|X\| \|Y\|} = \frac{\sum_{i=1}^n x_i \times y_i}{\sqrt{\sum_{i=1}^n (x_i)^2} \times \sqrt{\sum_{i=1}^n (y_i)^2}}$$

即将之映射成 n 维空间中的向量计算相似度

例如：对电影进行聚类 将特征上映国家和影片类型编码映射

	国家	类型
电影1	5	1
电影2	2	5
电影3	3	4



$$\cos\text{Sim}(\text{电影3}, \text{电影1}) = 0.75$$

$$\cos\text{Sim}(\text{电影3}, \text{电影2}) = 0.97$$

电影3与
电影2更
相似

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，
将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，
将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，
将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，
将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，
将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$,
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的
距离，将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有
点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心
没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值

早餐供应点位置示意



50个小区，5个早餐供应点

03. 聚类： K-Means算法


核心步骤

- ① **初始化**：给定样本集合 $X = (x_i)_{i=1:n}$ ，
随机初始化 K 个聚类中心
- ② **分配样本点**：计算每个点到聚类中心的距离，
将之分配到最近的聚类中心
- ③ **更新聚类中心**：利用每一类簇中所有点的均值作为新的聚类中心
- ④ **反复迭代**：重复②③，直到聚类中心没有更新，
或到达迭代的最大代数

距离函数：欧式距离

聚类中心：类/簇中所有点的平均值



早餐供应点位置示意



50个小区，5个早餐供应点


03. 聚类： K-Means局限性

对聚类中心的初始值敏感，不同起始点结果不同
对噪声和离群点数据敏感，容易导致中心点偏移



聚类 (Clustering)


- 将数据集按相似度分成多个子集（通常不相交），每个子集称为一个类或簇 (Cluster)，使得类/簇内相似度高，类/簇间相似度低





03. 聚类：层次聚类算法

自底向上（凝聚）法

- 一开始每个数据点看作一个簇
- 衡量簇之间的相似度，将相似度高的小簇合并成为更大的簇
- 终止条件：到达合并簇距离阈值或簇数阈值



系统树图




组间相似度计算

03. 聚类：层次聚类算法

自底向上（凝聚）法

- 聚类动画演示




03. 聚类：层次聚类算法

自顶向下（分裂）法

- 从数据点集合向下递归地划分成树状结构
- 终止条件：树的高度达到特定要求或每个节点包含的数据数目少于预定值
- 优点：可以更好地控制树的整体结构，如树的度和分支之间的平衡性
- 二分K-Means算法
 - ◆ 每个结点分裂成两个孩子节点
 - ◆ 增长策略
 - 优先分裂所含数据点最多的节点
 - 优先分裂与根节点最近的节点

聚类 (Clustering)


- 将数据集按相似度分成多个子集（通常不相交），每个子集称为一个类或簇 (Cluster)，使得类/簇内相似度高，类/簇间相似度低



03. 聚类：基于密度的算法

DBSCAN算法（出发点：可以对任意形状的簇进行聚类）

- 记半径为 Eps ，密度为 τ ，将数据点分类为
 - ◆ **核心点**：至少包含 τ 个数据点
 - ◆ **边界点**：包含小于 τ 个数据点且半径内至少包含1个核心点
 - ◆ **噪点**：既不是核心点也不是边界点
- 步骤：从某个核心点出发，不断向密度可达的区域扩张，从而得到一个包含核心点和边界点的最大化区域，区域中任意两点密度相连



Algorithm DBSCAN (数据: $\mathcal{D}$, 半径: Eps , 密度: τ)

begin

在 $\mathcal{D}$ 中以 (Eps, τ) 为基准，找出核心、边界和噪声点；


创建一个图，若其中每两个核心点是连接在一起的，并且它们之间的距离在 Eps 内，则在两个点间连一条边；

找出图中的所有连通子图；

为每个边界点找一个与之具有最强连接的连通子图；


return 作为簇的每个连通子图中的点；

end



03. 聚类：基密度的算法

DBSCAN算法聚类动画



目录



01

数据准备阶段

02

关联模式挖掘

03

聚类

04


分类

04. 分类：垃圾邮件鉴别

Messages 1 to 50 of 297	1
submission3@academicproofreadi... Wed 10:49	
★ [SPAM] English Proofreading and Editing	
专注澳洲, 新西兰, 太平洋群岛 因为专一, ... Wed 09:50	
★ [SPAM] 专注澳洲, 新西兰, 太平洋群岛 因为专一, 所以专一	
MLCR 2022 Wed 09:30	
★ [SPAM] EI/CPCI检索, MLCR 2022苏州*投稿6月15日截止	
adn@zhimengcn.cn Wed 07:45	
★ [SPAM] 评职, 评奖, 毕业, 考博发论文的老师看过来!!!	
Journal of Clinical Images and Med... Wed 05:07	
★ [SPAM] Full Waiver on Publication fee: Journal of C...	
Jessica Brown Tue 16:54	
★ [SPAM] Share your research on pathology	
cdfert@hotmail.com Wed 04:37	
★ [SPAM] 进出口报关13530236312	
cdfert@hotmail.com Wed 04:37	
★ [SPAM] 买单报关18823377690	



如何鉴别垃圾邮件，过滤
杂信息




分类问题

04. 分类：二分类与多分类


分类问题是**监督学习**的一个核心问题

- 如果将邮件分为垃圾邮件与正常邮件，则是一个二分类问题
- 如果将邮件分为工作、生活、通知、广告邮件等，则是一个多分类问题

二分类




多分类



04. 分类：算法流程

两个阶段

- 学习阶段：通过训练数据（带标签的样例）构建分类模型
- 分类阶段：通过分类模型预测未知数据（不带标签的实例）的类标签




04. 分类：决策树概念

决策树：

- 分层树形结构，由根节点、内部节点和叶节点组成。
- 代表对象属性与对象值之间的一种映射关系

决策树学习：

- **有监督学习**，从数据产生决策树
- 通过训练集中归纳出一组划分准则
- 使树的每个分支类变量的“混杂”程度逐层减小且尽可能小



04. 分类：决策树算法

算法步骤：

例：判断捐赠倾向 ($n=11, d=3$)

姓名	年龄	薪资	是否捐赠?
Nancy	21	37,000	N
Jim	27	41,000	N
Allen	43	61,000	Y
Jane	38	55,000	N
Steve	44	30,000	N
Peter	51	56,000	Y
Sayani	53	70,000	Y
Lata	56	74,000	Y
Mary	59	25,000	N
Victor	61	68,000	Y
Dale	63	51,000	Y

04. 分类：决策树算法

算法步骤：

① 将所有数据看作一个节点；

例：判断捐赠倾向 ($n=11, d=3$)

○ 根节点


Nancy	N	Jane	N	Sayani	Y	Victor	Y
Jim	N	Steve	N	Lata	Y	Dale	Y
Allen	Y	Peter	Y	Mary	N		

04. 分类：决策树算法

算法步骤：

- ① 将所有数据看作一个节点；
- ② 从所有特征（属性）中**挑选一个属性**
对该节点进行划分；

例：判断捐赠倾向 ($n=11, d=3$)




04. 分类：决策树算法

算法步骤：

- ① 将所有数据看作一个节点；
- ② 从所有特征（属性）中**挑选一个属性**
对该节点进行划分；
- ③ 生成若干子节点，依次判断每个子节点**是否满足停止分裂条件**：
若是，跳转 ④；
否则，跳转 ②；

例：判断捐赠倾向 ($n=11, d=3$)




04. 分类：决策树算法

算法步骤：

- ① 将所有数据看作一个节点；
- ② 从所有特征（属性）中**挑选一个属性**
对该节点进行划分；
- ③ 生成若干子节点，依次判断每个子节点**是否满足停止分裂条件**：
若是，跳转 ④；
否则，跳转 ②；
- ④ 设置该节点是叶节点，**对应类别定义**
为该节点在训练数据上数量占比最大的类别。

例：判断捐赠倾向 ($n=11, d=3$)




04. 分类：决策树算法

算法步骤：

- ① 将所有数据看作一个节点；
- ② 从所有特征（属性）中**挑选一个属性**
对该节点进行划分；
- ③ 生成若干子节点，依次判断每个子节点**是否满足停止分裂条件**：
若是，跳转 ④；
否则，跳转 ②；
- ④ 设置该节点是叶节点，**对应类别定义**
为该节点在训练数据上数量占比最大的类别。

例：判断捐赠倾向 ($n=11, d=3$)




04. 分类：决策树算法

问题：如果给定一个新样本，
预测她是否捐赠？

姓名	年龄	薪资	是否捐赠
Cindy	27	37,000	?



例：判断捐赠倾向 (n=11, d=3)



04. 分类：决策树算法

问题：如果给定一个新样本，
预测她是否捐赠？


姓名	年龄	薪资	是否捐赠
Cindy	27	37,000	?

预测结果：不捐赠

核心问题：

- 如何选择分裂特征？
- 何时停止节点分裂？

例：判断捐赠倾向 ($n=11, d=3$)





04. 分类：决策树划分准则

什么是好的划分准则？

- 使决策树的分支节点所包含的样本尽可能属于同一类别。

例：两种划分示例



04. 分类：决策树划分准则

什么是好的划分准则？

- 使分支节点所含样本尽可能属于同类别



错误率 (Error Rate)

- 令 p 为数据集 S 中属于**主导类别**的实例比例，则错误率为 $1 - p$
- 选择错误率最低的划分

$$\text{Error}(S, \text{年龄} = 50) = \frac{2}{11}$$

$$\text{Error}(S, \text{薪资} = 60,000) = \frac{2}{11}$$

例：两种划分



04. 分类：决策树划分准则

基尼系数 (Gini Index)

- 反映从数据集中随机抽取两个样本，其类别标记不一致的概率
- 数据集 S 中数据点的类别分布为 $p_1, \dots, p_k$ ，其基尼系数为

$$\text{Gini}(S) = 1 - \sum_{k=1}^K p_k^2$$

- 属性 a 将集合 S 划分为 r 个子集 $S_1, S_2, \dots, S_r$ ，其基尼划分系数为：

$$\text{GiniSplit}(S, a) = \sum_{i=1}^r \frac{|S_i|}{|S|} \text{Gini}(S_i)$$

- 选择使得 GiniSplit 最低的属性划分，即： $a^* = \operatorname{argmin}_a (\text{GiniSplit}(S, a))$



04. 分类：决策树划分准则

$$\begin{aligned} \text{GiniSplit}(S, \text{年龄} = 50) = & \frac{5}{11} \left(1 - \left(\frac{1}{5} \right)^2 - \left(\frac{4}{5} \right)^2 \right) + \\ & \frac{6}{11} \left(1 - \left(\frac{5}{6} \right)^2 - \left(\frac{1}{6} \right)^2 \right) = \mathbf{0.297} \end{aligned}$$

$$\begin{aligned} \text{GiniSplit}(S, \text{薪资} = 60,000) = & \frac{7}{11} \left(1 - \left(\frac{2}{7} \right)^2 - \left(\frac{5}{7} \right)^2 \right) + \\ & \frac{4}{11} \left(1 - \left(\frac{4}{4} \right)^2 - \left(\frac{0}{4} \right)^2 \right) = \mathbf{0.260} \end{aligned}$$

$$\text{GiniSplit}(S, a) = \sum_{i=1}^r \frac{|S_i|}{|S|} \text{Gini}(S_i), \text{Gini}(S) = 1 - \sum_{k=1}^K p_k^2$$

例：两种划分示例



04. 分类：决策树停止条件

决策树总体流程是自根至叶的递归过程，在每个内部节点根据划分准则寻找一个划分属性。停止条件决定了什么时候停止分裂。

停止条件1

当前节点包含的样本全属于同一类别，无需划分

停止条件2

样本的属性取值都相同或属性集为空，不能划分

停止条件3

当前节点包含的样本量少于阈值，不再划分

数据挖掘简介

- 数据挖掘的概念、经典案例、主要过程

数据准备阶段

- 数据类型：非依赖型数据、依赖型数据
- 数据清洗、数据归约、数据变换

关联模式挖掘

- 基本概念（频繁项集、支持度、置信度、关联规则）
- 关联规则生成框架
- 频繁项集挖掘算法（暴力、Apriori、枚举树）

聚类


- 基于划分的聚类算法（K-Means）
- 层次聚类算法（自底向上、自顶向下）
- 基于密度的算法（DBSCAN）

分类

- 决策树（划分准则、停止准则）

《数据挖掘：原理与实践》

- 基础篇：详细介绍了针对数据挖掘的四个主要问题（聚类、分类、关联模式挖掘和异常分析）的各种解决方法。
- 进阶篇：讨论了用于不同数据领域（例如时序数据、序列数据、空间数据、图数据）的特定挖掘方法，以及重要的数据挖掘应用（例如Web数据挖掘、排名、推荐、社交网络分析和隐私保护）。



谢谢！

