


《计算机科学导论》课程

推荐系统

上海交通大学计算机科学导论课程组



致谢：本课件由刘庆民@CS2018M.SJTU编写，刘雨桐@CS2017D.SJTU修缮排版，李豫晨@CS2019D.SJTU添加内容，高晓涵和孔令和终校定稿。



目录

01

推荐系统简介

02

推荐系统算法

03

推荐系统应用

CCTV 1

综合

倒计时 10:10

02.57.com

星辰观察

董星辰

3分钟自我展示

中央广播电视总台 中国劲酒·金标

主持人大赛

推荐系统简介




什么是推荐系统？

- 一种信息过滤系统，用于预测用户对物品的评分或偏好

它能做什么？

- 挖掘在节点间可能产生的连接



设计要诀：已经存在的连接 → 未来的连接

推荐系统发展史

1994

明尼苏达大学，第一个自动化推荐系统诞生



2003

亚马逊公布基于物品的协同过滤算法



2016

油管提出基于内容的推荐系统



2023

腾讯提出基于元学习的冷启动推荐模型



1997

美国电话电报公司首次提出“推荐系统”一词



2006

网飞举办电影推荐算法竞赛



2019

阿里巴巴提出基于生成对抗网络的用户兴趣模型





目录

01

推荐系统简介

02

推荐系统算法

03

推荐系统应用

推荐系统可以利用的信息:

类别	特征
物品特征	关键词、类别、品牌等
用户特征	性别、年龄、地域、画像等
用户-物品交互	评分、购买数、喜欢、转发等

常用推荐 算法分类

基于内容 (Content-based)

主要使用用户和物品的特征信息

协同过滤 (Collaborative Filtering)

主要基于用户-物品交互

结合新技术的新兴算法

图嵌入、深度学习.....

基于内容的推荐系统

基本思想： 基于用户曾经喜爱的物品列表，向其推荐相似物品

当推荐**不同类别**的物品时，可以利用的特征也不同，例如：

电影 相同的演员，导演，电影风格...

新闻 相似的主题，事件，人物...

书籍 相似的书名，作者，类型...

喜欢这部电影的人也喜欢 ·····



1917



地狱尖兵



波斯语课




灰猎犬号

喜欢读“平凡的世界”的人也喜欢 ·····



人生



围城



骆驼祥子



边城

豆瓣网

基于内容的推荐步骤

物品表示

提取**特征**表示候选物品，如类别、品牌等

用户偏好学习

利用用户与物品的**历史交互**数据，学习用户偏好特征

生成推荐


比较用户偏好特征与候选物品特征，推荐**最相关**的物品

物品表示

表示物品需要对其**特征**进行编码，变为**向量**形式
例如在电影网站上，物品即不同的电影

常见特征 类别、国家、主角、导演、出品年份等

向量表示：“成龙主演的某动作片在中国大陆上映”



用户行为序列

定义： 用户曾点击过的一组物品序列， 常可反映用户的兴趣偏好

一个喜欢**动作片**与**爱情片**的用户过去一周的电影点击序列

通过物品表示形成一组**电影表示向量**的序列

1 1 0 1 0 0 1 1 1 1 0 0 0 0 1 1 0 1 0 0 0 1 0 1 0



.....

时间线

用户偏好学习

通过用户历史**行为序列**学习
用户偏好

例如：当推荐**某最新动作片**
给该用户时

- ① 计算该影片与历史影片的**相似度**
- ② 利用加权求和计算用户
偏好表示向量



相似度计算

将不同**物品**表示成**向量**，计算**相似度**，来表示用户偏好

例如：

- 向用户推荐电影 I ，该用户的历史点击电影序列为 I_A 和 I_B
- 电影由两种特征表征：影片类型、上映国家

余弦相似度：

$$\cos(\theta) = \frac{a \cdot b}{|a| \times |b|}$$

	国家	类型
电影 I_A	5	1
电影 I_B	2	5
新电影 I	3	4

类型

电影 I_B

新电影 I

$$\alpha_A = \cosSim(I_A, I) = 0.75$$

$$\alpha_B = \cosSim(I_B, I) = 0.97$$

电影 I_A


国家

当推荐电影 I 时，用户偏好表示为：


$$\begin{aligned} & \frac{\alpha_A}{\alpha_A + \alpha_B} * I_A + \frac{\alpha_B}{\alpha_A + \alpha_B} * I_B \\ &= 0.44 * I_A + 0.56 * I_B \end{aligned}$$

常用相似度


余弦相似度 (Cosine Similarity)




杰卡德相似度 (Jaccard Similarity)




欧几里得距离 (Euclidean Distance)



曼哈顿距离 (Manhattan Distance)



切比雪夫距离 (Chebyshev Distance)



闵可夫斯基距离 (Minkowski Distance)

皮尔逊相关系数 (Pearson Correlation Coefficient)

斯皮尔曼相关系数 (Spearman Correlation)

例：闵可夫斯基距离 (Minkowski Distance)


- 变量 $a(x_{11}, \dots, x_{1n})$ 与 $b(x_{21}, \dots, x_{2n})$ 的闵可夫斯基距离定义为：

$$D(a, b) = \left(\sum_{i=1}^n |x_{1i} - x_{2i}|^p \right)^{\frac{1}{p}}$$

- $p=1$, 曼哈顿距离
- $p=2$, 欧几里得距离
- $p \rightarrow \infty$, 切比雪夫距离

如何处理超长用户行为序列？

余弦相似度提取用户偏好的计算量 $\propto N$ (用户行为序列长度)
只能记录最近几百个物品（短期偏好），否则计算量太大



参考文献：Qi et al. Search-based User Interest Modeling with Lifelong Sequential Behavior Data for Click-Through Rate Prediction. In CIKM, 2020.


特征交叉

不同特征经过关联交叉后，与预测目标的相关性可能更高

- “21-25岁的女生更可能喜欢看爱情电影”
- “年轻男孩对动作格斗片的兴趣更高”


学习用户特征与候选物品特征的交叉特征


喜欢	国家	类别	年龄	性别
1	中国	爱情片	21-25	女
1	美国	动作片	16-20	男
0	中国	记录片	11-15	男



将**用户特征**，**偏好特征**，**物品特征**，**交叉特征**作为输入，预估**点击率**、**点赞率**等分数

融合预估分数，判断用户**是否**喜欢某个商品






02.推荐系统算法：协同过滤 (Collaborative Filtering)

利用用户的交互来过滤感兴趣物品。可以将交互的集合可视化为一个矩阵，其中每一项 (i, j) 代表用户 i 和物品 j 的交互。

利用矩阵分解，补全评分矩阵 (R) 中的未知用户-物品交互，可得到两个新的矩阵 U 和 I ，满足 $U \times I$ 和 R 的所有已知项相等。那么， $U \times I$ 也提供了 R 中未知项的值，这些值可以用来生成推荐。



02.推荐系统算法：协同过滤 (Collaborative Filtering)

- 基于**用户**的协同过滤算法 (UserCF)
 - 最古老的推荐系统算法，其诞生标志了推荐系统的诞生
 - 主要包括两个步骤：
 1. 找到和目标用户兴趣相似的用户集合
 2. 找到这个集合中的用户喜欢的，且目标用户没有听说过的物品推荐给用户
- 基于**物品**的协同过滤算法 (ItemCF)
 - 目前业界应用较多的算法
 - 亚马逊、Netflix、Hulu、YouTube等的基础推荐算法
 - 主要包括两个步骤：
 1. 计算物品之间的相似度
 2. 根据物品的相似度和用户的历史行为给用户生成推荐列表

02.推荐系统算法：协同过滤（Collaborative Filtering）

UserCF和ItemCF优缺点对比

	UserCF	ItemCF
性能	适用于用户较少的场景，如果用户数量很多，计算用户相似度矩阵代价很大	适用于物品数目明显小于用户数的场合，如果物品很多（网页），计算物品相似度矩阵代价很大
领域	推荐更社会化，用户个性化兴趣不太明显的领域	推荐更个性化，长尾物品丰富，用户个性化需求强烈的领域
实时性	用户有新行为，不一定造成推荐结果立刻变化	用户有新行为，一定会导致推荐结果的实时变化
推荐理由	很难提供令用户信服的推荐解释	利用用户的历史行为给用户做推荐解释，可以令用户比较信服

02.推荐系统算法：图嵌入 (Graph Embeddings)

淘宝（阿里公司）基于图嵌入的推荐算法

获得用户
行为序列




构建有
向图




获得随机
游走序列




神经网络
训练




(a) Users' behavior sequences.



(b) Item graph construction.



(c) Random walk generation.



(d) Embedding with Skip-Gram.

DeepWalk (阿里, 2014) → Node2Vec (Stanford 2016) → EGES (阿里, 2018) → EventKG (UIUC, 2021)

董星辰
3分钟自我展示

崔爽

新闻类 目前排名第二


崔爽



“人们的信息领域会习惯地被自身兴趣所引导，从而将生活桎梏于像蚕丝般一样的「**茧房**」中。”

大量的信息流平台通过算法来迎合我们，
投喂**相似的内容**

如何突破信息茧房？



桑坦斯——《信息乌托邦》

投票：如何突破“信息茧房”？

如果使用“内容推荐”算法，以下哪个选项可以最快突破“信息茧房”？

- A. 完善个人用户信息
- B. 屏蔽不感兴趣的推荐
- C. 点击更多其他内容
- D. 不再查看推荐栏目

如果使用“内容推荐”算法，以下哪个选项可以最快突破“信息茧房”？

- A. 完善个人用户信息
- B. 删掉不感兴趣的推荐
- C. 点击更多其他内容**
- D. 不再查看推荐栏目

如果使用“内容推荐”算法，以下哪个选项可以最快突破“信息茧房”？

A. 完善个人用户信息 ❌

解析：当用户填写了新的信息后，在一定程度上可以缓解信息茧房的影响，为系统提供更多推荐的可能，但是本质上还是无法探索和扩展用户的兴趣边界



京东



淘宝



美团



网易词典

如果使用“内容推荐”算法，以下哪个选项可以最快突破“信息茧房”？

B. 删掉不感兴趣的推荐 

解析：删除不感兴趣的内容后，系统还是在用户原先的偏好下推荐内容，无法为用户提供更新颖的内容

C. 点击更多其他内容 

解析：可以扩展兴趣边界，帮助系统提供更加多元化的内容，从而突破信息茧房

D. 不再查看推荐栏目 

解析：违背了推荐系统的初衷



目录

01

推荐系统简介

02

推荐系统算法


03

推荐系统应用

03.推荐系统应用：应用流程

推荐系统应用的一般流程：

- 建立用户与物品数据库
- 提取用户与物品特征
- 应用推荐算法获得推荐结果
- 向用户展示推荐结果



以视频推荐领域为例

推荐系统应用

已被广泛用于诸多领域，国内涌现了一大批互联网企业，引领推荐系统的研究

电子商务



拼多多
拼团社交

电影视频



抖音
自媒体运营

音乐电台



网易云音乐
音乐社交

个性化阅读



知乎
知识平台

《麻省理工科技评论》将“抖音推荐技术”评为2021年全球十大突破性技术

推荐系统概念


- 用于预测用户对物品的评分或偏好

推荐系统算法

- 物品表示：将属性编码为向量
- 用户偏好学习：根据用户行为学习偏好
- 生成推荐：训练神经网络

推荐系统应用

- 电子商务、新闻资讯、电影/音乐/阅读推荐等



谢谢！

