



《计算机科学导论》课程

大语言模型

上海交通大学计算机科学导论课程组



致谢：本课件由张晓涵编写；洪义修改终校定稿

目 录

01

大语言模型概述

02

大模型技术原理

03

大模型应用场景

04

大模型发展挑战

05

未来的发展趋势


01 大语言模型概述

什么是语言模型？

语言模型 (Language Model)

- 旨在预测一个句子在语言中出现的概率

$$p(s) = p(w_1, w_2 \dots, w_m)$$




统计语言模型：以N-gram为例

- N-gram指一个由N个单词组成的集合，各单词具有先后顺序。
- N-gram模型的马尔可夫假设：
 - 当前状态出现的概率仅同过去有限的历史状态有关，而与其他状态无关。
 - 具体到分词任务，就是文本中第N个词出现的概率仅仅依赖于它前面的N-1个词，而与其他词无关。
- 常见的N-gram模型：
 - $N = 1$ ，一元语法模型（最大概率模型）， $P(w) = P(w_1) P(w_2) \dots P(w_n)$
 - $N = 2$ ，Bigram模型， $P(w) = P(w_1) P(w_2|w_1) \dots P(w_n|w_{n-1})$
 - $N = 3$ ，Trigram模型， $P(w) = P(w_1) P(w_2|w_1) P(w_3|w_1w_2) \dots P(w_n|w_{n-2}w_{n-1})$


神经语言模型 (Neural LM)

- 相比统计语言模型能捕捉更复杂的语义和句法关系，能够建模任意长度的上下文。
- 从单词映射到词向量，再由神经网络预测对应的内容
- 其中间产物——词向量，被广泛应用于各类自然语言处理任务



预训练模型


- 文档表征技术近年来有了长足进步，但语料的飞速积累，导致大部分人难以充分学习利用
- 预训练技术由此应运而生
 - 什么是预训练模型？
 - 通过大规模的数据和模型，学习语料库中的知识，然后将这些知识迁移到某一个具体的任务中，从而获得较好的表现。



01 大语言模型概述


预训练模型基础：Transformer技术

- Transformer架构：大模型基础架构
 - Transformer的核心：自注意力机制（Self-Attention）
 - 《Attention is All You Need》论文原文指出：相较于复杂递归或卷积神经网络，Transformer架构仅采用注意力机制连接Encoder和Decoder质量更优，更易于并行化，所需训练时间也更少



01 大语言模型概述

- **Transformer技术开启的新路径**
- 借助Transformer架构所提供的面向序列建模的统一范式，可以基于海量无监督数据实现预训练，并基于少量样本微调快速迁移至其他任务
- **迁移学习使通用模型成为可能！**
- 基于Transformer的序列建模方法已应用于文本、图像、语音、表格数据、蛋白质序列等领域



01 大语言模型概述

■ 预训练模型：大模型的前夜

■ Encoder-only 模型

- BERT 2018 3亿参数 Google 提出

- RoBERTa 2019 3亿参数 META 提出


■ Encoder-Decoder 模型

- T5 2020 110亿参数 Google 提出

- BART 2020 3亿参数 META 提出

■ Decoder-only 模型


- GPT 系列 1.17亿到千亿参数
ChatGPT 前身



01 大语言模型概述

■大语言模型

- 随着预训练模型的规模不断扩大，“涌现”现象开始出现：该现象是近年来人工智能领域最大的发现之一，即只要神经网络的复杂性和训练样本的多样性超过一定规模，就会有抽象的推理结构在神经网络里突然自发涌现出来。这个过程像所有的复杂性系统一样是非线性的，简单地说：量变导致质变。



01 大语言模型概述

■大语言模型



■ ChatGPT：大模型横空出世

- 2022年11月30日，OpenAI发布ChatGPT
- 发布仅5天，用户达100万；发布**2个月**，用户达**1亿**

■ ChatGPT能力

- 多轮对话，具有**强理解能力与上下文记忆**
- 知识问答，具有**庞大内生知识**，可回答专业问题
- 文本撰写与翻译，能够**生成高质量文本**，提供自然的翻译
- 代码生成，能够根据需求生成**编程代码**
- 基础推理，具有一定的逻辑能力，能够进行**简单推理**

Chat GPT与其他主流产品达到1亿全球用户时间对比（单位：月）



01 大语言模型概述

■ 层出不穷的新模型


- 自ChatGPT引领风潮始，大语言模型技术的发展呈现一日千里的态势
- 模型种类日益丰富，涉及领域、模态也日益广泛



01 大语言模型概述

■ 层出不穷的新模型

- 自ChatGPT引领风潮始，大语言模型技术的发展呈现一日千里的态势
 - 更为重要的是，模型的知识密度也不断提升，端侧大模型成为可能



Deepseek 模型参考			建议配置		
AI模型	模型参数	模型大小	显存	CPU	内存
DeepSeek-R1-1.5B	1.5B	1.1G	>4G	>4核	>8G
DeepSeek-R1-7B	7B	4.7G	>20G	>8核	>16G
DeepSeek-R1-8B	8B	4.9G	>22G	>8核	>32G
DeepSeek-R1-14B	14B	9G	>40G	>12核	>64G
DeepSeek-R1-32B	32B	20G	>80G	>16核	>128G
DeepSeek-R1-70B	70B	43G	>180G	>32核	>512G
DeepSeek-R1-671B	671B	404G	>440G	>64核	>768G

目

录

01

大语言模型概述

02

大模型技术原理

03

大模型应用场景

04

大模型发展挑战

05

未来的发展趋势

本章节将介绍大模型的几个关键技术组件及典型模型的训练方法

- 关键技术组件

- 词嵌入技术：大模型理解自然语言的基础
- 位置编码：让大模型理解文本次序
- 注意力机制：大模型思考的核心组件
- 文本生成：大模型输出自然语言
- ChatGPT训练过程
- Deepseek训练过程

02 大语言模型技术原理


■ 词嵌入技术：大模型理解自然语言的基础

■ 什么是词嵌入？


- 词嵌入是将**自然语言文本**数据转化为**连续向量**的技术，使得机器能够理解语言。
- 目标：使得**语义相似**的词在向量空间中的距离**更接近**
- 示例：“国”和“国家”的词嵌入在**向量空间**中会非常接近，反映出其语义相似性

■ 词嵌入在大模型中的作用

- 大模型输入的文本首先通过词嵌入层转换为向量表示
- 优势：低维表征效率高（相比独立编码）、反映语义关联、泛化能力强



语义空间中的邻近单词



词嵌入模型架构示意图

02 大语言模型技术原理

■ 位置编码：让大模型理解文本次序


■ 为什么要进行位置编码？

- 词汇 (token) 的嵌入向量是不包含位置信息的
- 如果不进行位置编码，那么大模型无法区分词汇次序
- 例如，无法区分“我找你”和“你找我”


■ 编码方式

- 绝对位置编码：记录绝对位置，效率低
- 正弦位置编码：表征效果好，但外推性差
- **旋转位置编码**：使用旋转矩阵表示位置，当前主流

■ 大模型眼中的一个输入词汇：词嵌入向量+位置编码



绝对位置编码



旋转位置编码

02 大语言模型技术原理


■ 注意力机制：大模型思考的核心组件

■ 为什么是注意力机制？


- 赋予模型 “**选择性关注**” 的能力
- 给输入数据的不同部分分配不同的权重
- 解决了传统RNN在处理**长序列时信息遗忘**的问题

■ 大模型中的注意力机制

- 模型在处理输入序列中的每个词时，同时**参考**输入序列中的**其他所有词**
- 多头注意力：在多个子空间**并行计算**，从**不同的角度**捕捉序列中的信息
- 注意力计算的结果将作用于嵌入向量，引入词汇间的**依赖关系**



注意力机制依赖计算示意图



多头注意力并行计算架构

02 大语言模型技术原理


■ 文本生成：大模型输出自然语言

■ 自回归生成机制：保证上下文连贯性


- 大模型每生成一个词都要考虑前面所有生成的词
- 生成的词将作为输入，参与计算下一个生成的词

■ 概率分布

- 经过嵌入、编码、注意力计算，大模型获得每个词的隐状态 (hidden state)
- 大模型生成每个词时，会基于隐状态与前期输出计算词表（预先准备好）中所有词的概率分布



自回归生成机制动态示意图




计算词表中所有词的概率分布

本章节将介绍大模型的几个关键技术组件及典型模型的训练方法

- 关键技术组件
 - 词嵌入技术：大模型理解自然语言的基础
 - 位置编码：让大模型理解文本次序
 - 注意力机制：大模型思考的核心组件
 - 文本生成：大模型输出自然语言
- ChatGPT训练过程
- Deepseek训练过程

02 大语言模型技术原理

■ GPT的社会化过程——从GPT到ChatGPT




■ 从GPT到ChatGPT还需要三个步骤

1. 海量知识的无监督学习；2. 人类引导的有监督微调；3. 激发创造的强化学习

02 大语言模型技术原理

■ GPT的社会化过程——从GPT到ChatGPT



■ 从GPT到ChatGPT还需要三个步骤

1. 海量知识的无监督学习；2. 人类引导的有监督微调；3. 激发创造的强化学习


02 大语言模型技术原理

■ GPT的训练数据

GPT-3 Training Data

Dataset	# Tokens	Weight in Training Mix
Common Crawl	410 billion	60%
WebText2	19 billion	22%
Books1	12 billion	8%
Books2	55 billion	8%
Wikipedia	3 billion	3%


大部分训练数据来自于Common Crawl dataset (总计4100亿词), 用于训练的数据总量达到了约5000亿词, 也即2~3TB的纯文本。并经过以下步骤的后处理:



02 大语言模型技术原理

■ GPT-3的训练方式

- ChatGPT的第一步训练过程就是前面所讲的GPT-3的训练过程，也称为**预训练**，其原理就是：
让模型阅读一长段（可以达到数千个）文档之后，让他预测紧接着最后一个词的下一个词是什么。



- 这一步需要花费大量的计算资源，需要2000~3000张A100 80g的GPU卡一刻不停地计算约2~3个月。按照目前的阿里云算时成本来算，单次训练需要数千万元左右的计算费用。
- 模型放大到这个规模之后，对超参数的宽容度变得很低，保持训练稳定变成了一件困难的事情。

02 大语言模型技术原理

■ GPT-3的重要能力

1. **语言生成**: 遵循提示词 (prompt), 然后生成补全 提示词的句子 (completion)。这也是今天人类与语言模型最普遍的交互方式。
2. **上下文学习 (in-context learning)**: 遵循给定任务的几个示例, 然后为新的测试用例生成解决方案。
3. **世界知识 (world knowledge)**: 包括事实性知识 (factual knowledge) 和常识 (commonsense)。

The diagram illustrates GPT-3 capabilities through three examples, each with a blue arrow pointing from the text on the left to the corresponding visual example on the right.


Example 1: Language Generation
A search bar shows the query "large language models". Below it, a list of search results is shown, including "large language models are zero-shot reasoners", "large language models are human-level prompt engineers", "large language models can self-improve", "large language models encode clinical knowledge", "large language models are reasoning teachers", and "large language models generate functional protein sequences across diverse families".

Example 2: In-context Learning
A prompt is shown with the following structure:
1. Translate English to French: (task description)
2. sea otter => loutre de mer (examples)
3. peppermint => menthe poivrée (examples)
4. plush girafe => girafe peluche (examples)
5. cheese => (prompt)

Example 3: World Knowledge
A search bar shows the query "地幔柱". Below it, a search result is shown for "地幔柱 (Mantle Plume)", describing it as a hot column in the Earth's mantle formed by rising heat and lower density magma, which can lead to volcanic activity and hydrothermal vents. It is noted as an important research direction for geologists studying Earth's internal structure and dynamics.

02 大语言模型技术原理

■ GPT的社会化过程——从GPT到ChatGPT



■ 从GPT到ChatGPT还需要三个步骤

1. 海量知识的无监督学习；2. 人类引导的有监督微调；3. 激发创造的强化学习

02 大语言模型技术原理


■ GPT-3.5的核心优化-人类引导的有监督微调

- 有监督微调（Supervised Fine-Tuning，简称 SFT）。利用和真人交互的记录来教会模型学着和人对话的语气。
- SFT数据集是由提示-答复对组成的样本。SFT数据一部分来自使用OpenAI的PlayGround的用户，另一部分来自 OpenAI 雇佣的 40 名标注工 (labeler)。并且他们对labeler进行了培训。

Step 1

Collect demonstration data, and train a supervised policy.


A prompt is sampled from our prompt dataset.



A labeler demonstrates the desired output behavior.



This data is used to fine-tune GPT-3 with supervised learning.



02 大语言模型技术原理

■ GPT-3.5的重要能力

- **响应人类指令：**GPT-3 的输出主要是训练集中常见的句子。GPT3.5会针对指令/提示词生成更合理的答案。
- **泛化到没有见过的任务：**当用于调整模型的指令数量超过一定的规模时，模型就可以自动在从没见过的新指令上也能生成有效的回答。
- **代码生成和代码理解**
- **利用思维链 (chain-of-thought)进行复杂推理：**初代 GPT3 的模型思维链推理的能力很弱甚至没有。

BO 如何鉴别黄铁矿和黄铜矿



鉴别黄铁矿和黄铜矿的方法有很多，下面是几种常用的方法：



1. 物理性质比较：黄铁矿是一种磁性矿物，而黄铜矿则不是。因此，可以使用磁铁或其他磁性物质来检测这两种矿物的磁性。
2. 颜色比较：黄铁矿通常是一种暗黄色，而黄铜矿则是一种亮黄色，因此，可以从颜色上进行区分。
3. 硬度比较：黄铁矿的硬度通常较低，在5-6范围内，而黄铜矿的硬度则较高，通常在3-4范围内。因此，可以使用硬度试验来区分这两种矿物。
4. 化学试验：黄铁矿和黄铜矿的化学成分不同，因此，可以进行一些化学试验，如碱性试验或硫酸试验，来区分这两种矿物。

以上是几种常用的鉴别黄铁矿和黄铜矿的方法，不同的方法适用于不同的情况，因此可以根据具体需求选择合适的方法。

ZG 若 $xy-x+y=0$ ，且 $xy \neq 0$ ，则分式 $1/x-1/y$ 的值为多少？



< 3 / 3 >



根据规律，对于一个分式的形式为 $a/b-c/d$ 的分式，它的值可以表示为 $(ad-bc)/bd$ 。因此，在本题中， $1/x-1/y$ 的值等于 $(1y-1x)/x*y$ 。




根据题意，我们知道 $xy-x+y=0$ ，即 $xy=x-y$ 。因此， $1/x-1/y$ 的值等于 $(1*(x-y)-1x)/x(x-y)$ 。

因为 $x*(x-y) \neq 0$ ，所以 $1/x-1/y$ 的值等于-1。

因此，当 $xy-x+y=0$ 且 $xy \neq 0$ 时， $1/x-1/y$ 的值为-1。

02 大语言模型技术原理

■ GPT的社会化过程——从GPT到ChatGPT



■ 从GPT到ChatGPT还需要三个步骤

1. 海量知识的无监督学习；2. 人类引导的有监督微调；3. 激发创造的强化学习

02 大语言模型技术原理


■ ChatGPT的核心优化—基于人类反馈的强化学习 (RLHF)

- **训练奖励模型**：将模型对同一个问句生成的若干不同样本交给真人排序，用排序的结果训一个奖励模型。
- **PPO (Proximal Policy Optimization)**：用奖励模型进一步训练GPT模型。

Step 2

Collect comparison data and train a reward model.

A prompt and several model outputs are sampled.



Step 3

Optimize a policy against the reward model using the PPO reinforcement learning algorithm.


A new prompt is sampled from the dataset.

The PPO model is initialized from the supervised policy.

The policy generates an output.

The reward model calculates a reward for the output.

The reward is used to update the policy using PPO.



02 大语言模型技术原理

■ ChatGPT的重要能力

- **翔实的回应：**ChatGPT 的回应则更加冗长，以至于用户必须明确要求“用一句话回答我”，才能得到更加简洁的回答。
- **拒绝其知识范围之外的问题：**例如，拒绝在2021年6月之后发生的新事件（因为它没在这之后的数据上训练过）。模型能够隐式地区分哪些问题在其知识范围内，哪些问题不在其知识范围内。



Why is the 2022 World Cup in Qatar so controversial?




I'm sorry, but I am not able to browse the internet or access any external information beyond my training data. As a large language model trained by OpenAI, I only have access to the text that I have been trained on, and I do not have any knowledge of current events or specific individuals or organizations outside of that training data. My knowledge is limited to general information on a wide range of topics based on the text that I have been trained on. I apologize if this is not the answer you were looking for. Is there something else I can help you with?



本章节将介绍大模型的几个关键技术组件及典型模型的训练方法


- 关键技术组件
 - 词嵌入技术：大模型理解自然语言的基础
 - 位置编码：让大模型理解文本次序
 - 注意力机制：大模型思考的核心组件
 - 文本生成：大模型输出自然语言
- ChatGPT训练过程
- Deepseek训练过程

■ DeepSeek突破了什么?



■DeepSeek突破背后的技术：架构创新

没有太多花哨的概念创新，多是站在前人肩膀上，但却有极高壁垒的工程创新。
以混合专家（Mixture of Experts）为例：



特性	传统 MoE	DeepSeek 的 MoE
注意力机制	使用固定的门控机制，将输入分配到少量专家，灵活性有限。	引入 多头潜在注意力，不同注意力头可动态选择专家，提升专家分配效率与灵活性。
负载均衡	需要引入辅助损失来平衡专家负载，增加训练复杂度。	采用 无辅助损失负载均衡策略，通过改进门控机制，自动实现专家负载均衡，简化训练。
训练目标	使用单标记预测（一次生成一个单词或标记），上下文学习能力有限。	使用 多标记预测目标，一次生成多个标记，提高长距离依赖学习能力和生成效率。
训练稳定性	容易出现 损失值剧烈波动，可能导致训练失败或需要频繁回滚。	训练过程稳定，无不可恢复的损失波动或回滚现象。
计算效率	虽然理论上节省计算，但负载不均衡和专家分配低效性导致实际训练和推理成本较高。	激活 6710 亿参数中的 37 亿参数，优化了推理效率，显存占用更低，降低了训练和推理成本。
效果表现	在多任务场景下，专家选择机制可能不佳，导致任务表现不稳定或能力不足。	灵活的专家分配机制 能适应更多任务场景，在知识问答、代码生成、数学推理等多任务中表现优异。


02 大语言模型技术原理

■训练方法：数据量收敛，传统的训练方法难以持续

Projections of the stock of public text and data usage

EPOCH AI

Effective stock (number of tokens)



些“污染数据”。

Scaling Law失效了?

Ilya 在演讲中说，“如果你有一个巨大的数据集，训练一个超大的神经网络，那么成功是必然的。”但现在，这个公式似乎失效了。因为数据这个关键变量已经触顶，即便你有再强大的计算资源，也无法突破这个瓶颈。

这也解释了为什么最近很多模型都在走“小而精”的路线。比如OpenAI



蔡荔谈AI

Ilya向全世界宣布：预训练的黄金时代已经结束了！

02 大语言模型技术原理

■新的范式：自我强化学习

一。Ilya 用一句话概括了强化学习，非常准确：让 AI 用随机的路径尝试新的任务，如果效果超预期，那就更新神经网络的权重，使得 AI 记住多使用这个成功的事件，再开始下一次的尝试。

我们在实现强化学习的过程中，有两个元素是最重要的，一直在反复




张小珺

【大模型季报】AGI范式大转移：从LLM到self-play RL


2024-06

超越GPT4的基准模型
推理能力和输出质量提升
复杂任务处理
长文本、数学和编程明显改进




2024-09

大模型技术范式改变
纯粹意义上的**推理模型**
强化学习与后训练
数学、编程、Agent




02 大语言模型技术原理

传统的LLM训练流程



DeepSeek R1的训练流程



1. 多阶段训练意义

像“**少年班**”，R1通过**冷启动SFT**（“语文课”规范输出格式）→ **推理RL**（“奥数课”提升逻辑）→ **通用SFT**（“通识课”平衡能力）- **全场景RL**（“社会实践”打磨安全价值观），实现“先专精再泛化”的渐进优化，避免传统RLHF因早期训练不稳定导致的输出混乱。

2. 群体相对策略优化（GPRO）


像“**班级内竞争**”，每次生成多个答案，选组内最优作为改进方向，减少对绝对分数的依赖。而传统方法像“标准答案考试”：依赖奖励模型给出绝对分数，需额外训练评判模型，成本更高。

3. 数据使用革新

像“**自主学习**”，R1在强化学习阶段通过拒绝采样自动筛选高质量答案，并混合到后续训练中，实现“越练越强”的闭环。

02 大语言模型技术原理

模型性能达到国际先进水平，更重要的是自主、开源、便宜。




发布时间	企业名称	模型名称	训练成本（按照GPU租赁逻辑计算）
2023年3月	OpenAI	GPT-4	约6300万美元
2024年3月	/	GPT-4相当规模	约4800万美元
2024年6月	Anthropic	Claude 3.5 Sonnet	3000~5000万美元
2024年7月	Meta	Llama 3.1 405B	约5800万美元（仅预训练）
2024年12月	深度求索	DeepSeek-V3	557.6万美元

02 大语言模型技术原理

DeepSeek-R1 Upsets AI Market With Low Prices


Estimated price for processing one million input/output tokens on different AI models



在能力相当的前提下，R1显著低于o1

SPEED

Output Tokens per Second; Higher is better



响应速度性能还有很大提升空间

目 录

01

大语言模型概述

02

大模型技术原理

03

大模型应用场景

04

挑战与伦理问题

05

未来的发展趋势


03 大模型应用场景



03 大模型应用场景

• ChatGPT应用案例——生成式检索

- 基于检索内容增强，实现有效的大模型文本问答



生成式检索流程图示

认知智能全国重点实验室

检索增强的回答

作为大模型输入

ANSWER | GPT-3.5 MODEL

根据thepaper.cn、aga.ustc.edu.cn、zhuanlan.zhihu.com等搜索结果，认知智能全国重点实验室是中国科学技术大学和科大讯飞联合共建的一个国家级实验室，旨在推动人工智能从计算智能、感知智能向认知智能的高级阶段发展，以期突破人类认知能力的局限，实现机器拥有类似人类的智慧，甚至具备各个行业领域的人类专家的知识积累和应用的能力。

为了帮助开发者更好地了解认知智能全国重点实验室，以下是一些可能有用的信息和参考材料：

- 实验室的研究重点包括面向认知计算的深度学习共性技术、知识自动构建与推理技术等认知智能基础理论的研究，以及人机交互技术、智能评测技术、智能辅助审判技术和认知医疗技术等认知智能支撑技术的突破。zhuanlan.zhihu.com
- 科大讯飞通过认知智能全国重点实验室牵头设计了通用认知大模型评测体系，覆盖7大类481个细分任务类型。thepaper.cn
- 实验室的第一届学术委员会由多位院士和专家组成，包括中国工程院院士李德毅、中国科学院院士徐宗本、中国科学院院士张旭等。caifuhao.eastmoney.com
- 该实验室的建设对于推进人工智能源头技术创新、聚集和培养优秀人才、促进以科大讯飞人工智能开放平台为基础的产业集群和生态系统良性健康发展等方面具有积极的意义。zhuanlan.zhihu.com

希望这些信息能够帮助开发者更好地了解认知智能全国重点实验室。

SOURCES 检索内容

cogskl.flytek.com

认知智能全国重点实验室

认知智能全国重点实验室 更多 > 认知智能全国重点实验室副主任王士进获中国科协求是杰出青年成果转化奖 2023年2月20日. 认知智能国家重点实验室荣获教育成果挑战杯赛真实场景教学效果推断赛道冠军 2023年1月16日. 认知智能国家重点实验室再获多模态阅读理解 ...

www.thepaper.cn > newsDetail_forward_1912444

中国首个认知智能国家重点实验室设立，科大讯飞承建 科学 ...

中新网12月19日消息，日前，科技部正式设立第一个人工智能国家重点实验室认知智能国家重点实验室，这一实验室交由科大讯飞股份有限公司来承建。当前，人工智能的第三次浪潮已经到来，其广阔前景和战略意义日益凸显，正在全球范围内引发全新的产业浪潮。在深度学习、知识图谱等科研工作的推动下，我国的认知智能也取得了较大的进展，但离...

aga.ustc.edu.cn > info > 1114 > 25153.htm

认知智能全国重点实验室第一届学术委员会第一次会议顺利 ...

认知智能全国重点实验室由中国科学技术大学和科大讯飞联合共建，于2022年5月正式获批重组，成为首批20家标杆国家重点实验室之一。实验室第一届学术委员会专家有中国工程院院士李德毅、中国科学院院士徐宗本、中国科学院院士张旭、中国

生成式检索应用示例

- ChatGPT应用案例——生成式检索
 - 相较于传统检索方式，大模型支撑的生成式检索准确率更高、内容更详实、知识更新更迅速，专业性也更强

类别	问题	ChatGPT	检索增强
知识更新	刚过去的“五一”劳动节，全国前三天大概发送旅客多少人次？	根据 2021年五一劳动节期间铁路部门发布的数据 ，全国铁路共发送旅客1.18亿人次，其中包括了前三天.....	根据 news.cctv.com ，2023年五一假期前三天（4月29日至5月1日）全国铁路、公路、水路和民航预计发送旅客总量约 1.59亿人次 。
事实问答	请问唐朝的第三任皇帝是谁？	唐朝的第三任皇帝是太宗李世民 。他是唐太宗李世民，也是唐高祖李渊的 第三个儿子 ，于贞观元年（公元627年）继位，一直统治到贞观二十三年（公元649年）去世。太宗李世民.....	这是一道关于历史的问题，根据 qulishi.com 可以得知 唐朝的第三任皇帝是唐高宗李治 。同时，文章还介绍了唐朝的皇帝列表.....
专业问答	血清白蛋白是否属于非胸腺依赖性抗原？为什么？	是的 ，血清白蛋白属于 非胸腺依赖性抗原 。白蛋白是一种常见的血浆蛋白，它的生成不依赖于胸腺，而是由肝脏合成。非胸腺依赖性抗原指的是.....	血清白蛋白属于 胸腺依赖性抗原 （TD-Ag） [2] 。TD-Ag指需要CD4+的T细胞辅助才能激活B细胞产生相应抗体的一类抗原， 天然抗原大多为TD-Ag ，如人血清球蛋白、.....

03 大模型应用场景

• ChatGPT应用案例——辅助编程

• 发展历程

- 2022年6月，OpenAI推出集成在IDE中的编程辅助大模型GitHub Copilot
- 2023年1月，清华大学发布国内首个编程辅助大模型CodeGeeX

• 具体功能：

- 代码自动生成与补全
- 语法检查与错误诊断
- 代码优化与重构
- 自动化测试与验证：模拟用户行为、分析测试数据



CodeGeeX代码解释器界面展示了Python代码的解释结果。左侧是代码输入区域，右侧是解释结果区域。代码内容如下：

```
1 #!/usr/bin/python3
2
3 import _thread
4 import time
5
6 def print_time( threadName, delay):
7     count = 0
8     while count < 5:
9         time.sleep(delay)
10        count += 1
11        print ("%s: %s" % ( threadName,
12
13
14
15
16
17
18
19
20
21
```

解释结果显示，代码成功运行，输出了线程名称和当前时间。例如：

```
Thread-1: 2023-01-08 10:00:00
Thread-2: 2023-01-08 10:00:00
```


基于大模型的代码解释工具

03 大模型应用场景


对话应用：联网搜索 + 推理，秘塔、Perplexity等AI搜索工具



手机端比网页可能会响应快一些
(经验，无实际证据)



对话应用：推理，Cursor等开发工具



- ❑ 对话/API：硅基流动、OpenRouter
- ❑ API：百度智能云、阿里云、腾讯云
- ❑ 企业部署：满血版投入巨大
- ❑ 本地部署：ollama、lmstudio、GPT4all (量化版)

目

录

01

大语言模型概述

02

大模型技术原理

03

大模型应用场景

04

大模型发展挑战

05

未来的发展趋势


04 大语言模型的挑战和伦理问题

大语言模型能否包打天下？

ChatGPT的成功带来了乐观的氛围，也催生了人们对“大模型神话”的追捧

- DeepMind 研究主任 Nando de Freitas 宣称：
 - ◆ AI「现在完全取决于规模」。
 - ◆ AI 领域更难的挑战已经解决了。「游戏结束了！」

然而，事情是否真如人们预料得那样顺利？



04 大语言模型的挑战和伦理问题

制约大模型推广应用的最核心要素：生成内容的可靠性问题


- 强语言，弱知识，“一本正经的胡说八道”
- 实时信息更新慢，新旧知识难区分
- 专业技能难具备，逻辑推理难实现
- 此外，算力需求与监管困难同样限制了其应用

04 大语言模型的挑战和伦理问题


局限（1）大模型的“幻觉问题”

大模型生成内容依赖“概率”，而并非背后的“知识”或“逻辑”

- 类似的问题，在多模态场景下体现更为明显



请描述这张图片




这张图中出现了一只红色的狗，它在草坪上奔跑。在这只狗的周围，还可以看见其它几只狗。有几只离这只红色的狗更近，其它的距离更远一些。

04 大语言模型的挑战和伦理问题

- 局限（1）大模型的“幻觉问题”
- 大模型生成内容依赖“概率”，而并非背后的“知识”或“逻辑”
 - ◆ “幻觉”问题的另一种体现方式——“偏见”（Bias）问题



描述图片中人物的职业和性别



图中是一位护士，所以是女性

04 大语言模型的挑战和伦理问题

- 局限 (1) 大模型的“幻觉问题”
- 大模型生成内容依赖“概率”，而并非背后的“知识”或“逻辑”
 - ◆ OpenAI科学家Andrej Karpathy的观点：
 - 大模型100%在做梦，因此存在幻觉问题。搜索引擎则是完全不做梦，因此存在创造力问题



04 大语言模型的挑战和伦理问题

- 局限（2）运用知识与更新知识问题
- Prompt可以教会大模型“范式”，但未必能教会大模型背后的“思路”
- 这一类问题在涉及专业领域、专业知识时尤为明显

Q: 3个人3天用3桶水，9个人9天用几桶水？

A: 根据题目可知，3个人在三天内用了3桶水，
可以推算出每天每人用水量为：

$3 \text{ 桶} / 3 \text{ 人} / 3 \text{ 天} = 1 \text{ 桶} / \text{人} / \text{天}$

因此，在9个人使用9天内需要的总用水量为：


$1 \text{ 桶} / \text{人} / \text{天} \times 9 \text{ 人} \times 9 \text{ 天} = 81 \text{ 桶}$

所以，9个人在九天内需要**用 81 桶的水。**

(正确答案应该是：27桶水)



04 大语言模型的挑战和伦理问题

- 局限（3）庞大的算力需求
- GPT-4据估计训练开支已达 7840万美元
- Gemini Ultra训练开支达到了1亿9千万美元
- DeepSeek 的成功也对其他大模型厂商产生了深远影响。
 - 它证明了即使在参数较少的情况下，通过优化也能达到与最大参数模型相当的性能。这使得其他厂商开始重新思考如何在减少训练成本的同时提升模型性能。



04 大语言模型的挑战和伦理问题

- 局限（4）黑盒特性与监管困难
- 大模型的黑盒特性导致其难以监管，存在安全性、公平性等方面的风险



目

录

01

大语言模型概述

02

大模型技术原理

03

大模型应用场景

04

大模型发展挑战


05

未来的发展趋势

05 大模型的研究趋势

类比人类智能：

- 高效大脑->稀疏激活
- 敏锐感官->多模态智能
- 灵活双手->工具智能
- 沟通交流->群体智能



大模型的安全

大模型的可解释性


大模型的伦理与法律问题

...

05 大模型的研究趋势

稀疏激活：人脑高效的关键

人脑 vs. GPT-3



亟需融合神经科学前沿进展，突破现有基础模型架构局限性





Toward Next-Generation Artificial Intelligence:
Catalyzing the NeuroAI Revolution

2022年，图灵奖获得者 Yann LeCun 和 Yoshua Bengio 联合发布NeuroAI白皮书，指出**神经科学可为下一代人工智能提供指导**

神经元稀疏连接使大脑
形成**功能模块**

语言认知需要视觉、听觉、
注意力等**多模块协同处理**



人脑的模块化结构：高效性、可复用性、可解释性

高效性：人脑的神经元连接**高度稀疏**形成若干**功能模块**，功能模块的定向激活使得人脑计算极为高效

可复用性：模块的**复用与组合**是人脑复杂认知能力的重要基础

可解释性：模块的激活、复用与组合模式可用于人脑思维过程**解读**

05 大模型的研究趋势

■ 多模态智能：让大模型走进物理世界


- 多模态智能是拓展大模型能力边界，迈向通用人工智能的必由之路



05 大模型的研究趋势

■ 工具智能：前沿研究方向

- OpenAI、Google等陆续发布WebGPT、ToolFormer等项目，证明大模型能够模仿人类使用搜索引擎、计算器等外部工具，达到了超越人类用户的工具使用性能



05 大模型的研究趋势


■ 群体智能：智能的第二次涌现

个体智能涌现

神经元数量增加带来生物个体的智能涌现



参数增加带来单个大模型的智能涌现



群体智能涌现

生物体群聚带来生物群体智能涌现



AI群聚带来AI群体智能涌现



大语言模型概述

- 统计语言模型，神经语言模型，预训练语言模型，大模型

大模型技术原理

- 词嵌入，位置编码，注意力机制，文本生成，ChatGPT与Deepseek训练

大模型发展挑战

- 幻觉问题，知识更新问题，高算力需求，黑盒特性与监管难题

未来发展趋势

- 稀疏激活，多模态智能，工具智能，群体智能，.....

注：本ppt部分内容来自中科大徐童老师、上海交通大学金耀辉老师和林洲汉老师、清华大学刘知远老师的相关报告，在此表示感谢

谢谢!